



INSTITUTO FEDERAL
Goiás

Câmpus
Anápolis

Especialização em Inteligência Artificial Aplicada

Viagens Urbanas Inteligentes: Predição de tempo de viagens urbanas utilizando modelos de *Machine Learning e Redes Neurais Artificiais*

Marcos Rodrigues Brugnaro

Sumário

1. Introdução
2. Aquisição dos Dados
3. Pré-processamento dos Dados
4. Extração de atributos
5. Análise Exploratória dos Dados
6. Análise dos Experimentos
7. Análise Comparativa dos Experimentos
8. Conclusão
9. Referências

Introdução

- **Cidades conectadas na mobilidade urbana**

- Tecnologias impactam no contexto dos meios de locomoção das pessoas;
- Coleta dos dados sobre hábitos de transporte público por meio de dispositivos nos veículos e integração com outros sistemas;
- Desenvolvimento de automações para processar grandes volumes de dados.

- **Principais desafios enfrentados pelos passageiros**



- Incerteza no planejamento e no tempo de chegada do ônibus urbano;
- Insegurança e vulnerabilidade;
- Impacto na lotação;
- Irregularidade das linhas;
- Veículos lotados seguidos por veículos vazios (bunching);

- **Motivações**

- Integrar dados de geolocalização com outros sistemas;
- Maior confiança no sistema, evitando chegadas antecipadas ou longos tempos de espera;
- Experiência de transporte mais eficiente e confiável;
- Predições precisas do tempo de viagem de ônibus urbano.

- **Método KDD (Knowledge Discovery in Databases)**

- Descoberta de Conhecimento em bases de dados;
- Processo analítico, sistemático e automatizado;
- Uso de aprendizado de máquina, otimização e estatística para definir padrões relevantes nos dados (Silva, 2016);



Aquisição dos Dados

- Fontes dos dados

- UFPR (Curitiba URBS): repositório de dados com qualidade satisfatória desde janeiro 2017 - 2024;

Arquivos de Dados Brutos	
linhas.json	shapeLinha.json
pois.json	tabelaLinha.json
pontosLinha.json	tabelaVeiculo.json
trechosItinerarios.json	veiculo.json

- Seleção de datasets


- Foco em dados mais relevantes para o estudo;

Arquivos de Dados Brutos Selecionados	
linhas.json	
pontosLinha.json	
tabelaVeiculo.json	
tabelaLinha.json	
trechosItinerarios.json	

- Compreensão inicial dos dados

linhas	tabela_veiculo	tabela_linha	pontos_linha	trechos_itinerarios
cod nome somente_cartao categoria_servico nome_cor	cod_linha nome_linha veiculo horario tabela cod_ponto	hora ponto dia num tabela adapt cod	nome num lat lon seq grupo sentido tipo itinerary_id cod	cod_linha nome_linha cod_categoria nome_categoria cod_empresa nome_empresa cod_pto_parada_th nome_pto_parada_th nome_pto_abreviado seq_pto_iti_th cod_itinerario nome_itinerario pto_especial cod_pto_trecho_a seq_pto_trecho_a cod_pto_trecho_b seq_pto_trecho_b extensao_trecho_a_ate_b tipo_trecho stop_code stop_name codigo_urbs


- Seleção e nomeação dos dados;
- Elaboração do dicionário de dados;
- Primeiras observações e análises;



line	station	vehicle	accessibility_info	itinerary
line_id line_name line_color line_category line_payment_method	station_name station_code station_initial_latitude station_initial_longitude station_sequence station_direction station_type line_id	vehicle_plate vehicle_time line_id	accessibility_eletric_ramp accessibility_time accessibility_day line_id	itinerary_company_name itinerary_code itinerary_special_line line_id


Pré-processamento dos Dados

- Preparação dos dados para serem submetidos aos experimentos;
 - Requisições automatizadas;
 - Captação dos dados: Janeiro 2023 - 01 a 31 e Junho 2024 - 05 a 30.
- Etapas da Pipeline do Pré-processamento
 - Renomeação dos atributos;
 - Padronização dos nomes;
 - Validação do atributo "line_id";
 - Remoção de registros duplicados.



Extração de atributos


- Ampliação das características dos dados;
- Obter dados relacionados a distância e duração de tempo entre pontos inicial e final de cada rota;
- Integração com API do Google Maps.
- 10 primeiros registros de rotas:



- Rota com menor distância:



- Rota com maior distância:



- Pós-processamento dos dados
 - Limpezas complementares;
 - Identificação de novos atributos;
 - Remoção de valores nulos;
 - Substituição de valores nulos com base em estatísticas de atributos relacionados a latitude e longitude;
 - Transformação de atributos categóricos para numéricos;
 - Extração de atributos:
- Distância em quilômetros

$$\text{km} = \frac{\text{m}}{1000}$$

- Duração em minutos

$$m = \frac{s}{60}$$

- Velocidade média em quilômetros por hora


$$v = \frac{d}{t} \quad v = \frac{d}{t} \times 3.6$$

- Conversão de dados de tempo “vehicle_time” e “accessibility_info_time” de horas para minutos;
- Dataset pós-processado servirá como base para as próximas etapas de análise exploratória dos dados e experimentos.


Análise Exploratória dos Dados

• Visualização dos dados


- Comportamento simétrico e distribuição equilibrada em torno da mediana;



- Oferta proporcional de ônibus nos três turnos;
- Acessibilidade amplamente distribuída;




○ Distribuição multimodal



○ Distribuição bimodal

- Atributo “duration”:
- Variação de valores;
- Maioria das viagens entre 500 e 2000 segundos;
- Menor concentração entre 2500 e 3000 segundos e representa menos que 500 registros;
- Tendência central.




Análise Exploratória dos Dados

- Visualização dos dados atributo “duration”

- Trajetos com duração próxima à média;
- Agrupamento predominante: 493 trajetos com duração de 1.140 s. ou 19 min.

- Agrupamento menos frequente:: 4 trajetos com duração de 2.820 s. ou 47 min.;
- Tempos de viagem mais longos são menos frequentes, mas ainda relevantes para análises futuras.



- Visualização dos dados atributo “line_category”

- Agrupamento predominante: ALIMENTADOR com 5985 linhas;
- Agrupamento menos frequente: JARDINEIRA com 54 linhas.



Análise Exploratória dos Dados

• Estatística descritiva

Tamanho da amostra	12.372 registros, sem valores ausentes.
Média dos valores	Distância média: 12,49 km. Duração média: 33,42 minutos.
Desvios padrão	Distância: 7,41 km. Duração: 9,65 minutos.
Atributos Geográficos	Latitude: Mín: -25.625, Máx: -25.4278 Longitude: Mín: -49.378, Máx: -49.2731
Velocidades médias	Mín: 2,85 km/h, Máx: 20,64 km/h.
Maior trajeto	Linha: Jardim do Arroio - Estação Santa Cândida; Distância: 47,9 km; Velocidade média: 58,65 km/h; Duração: 49 minutos.
Menor trajeto	Linha: Cristo Rei - Estação Centro; Distância: 400m; Velocidade média: 12 km/h; Duração: 2 minutos.

• Detecção de outliers

Atributo	Quantidade dos Outliers
line_category	502
line_color	1448
line_payment_method	1422
accessibility_info_eletric_ramp	1095
station_initial_latitude	6
station_final_latitude	17
distance	333
average_speed_ms	440
average_speed_kh	440
duration	2

• Análise de correlação entre atributos

$$r_{v_1, v_2} = \frac{\sum_{i=1}^n (v_{1i} - \bar{v}_1)(v_{2i} - \bar{v}_2)}{\sqrt{\sum_{i=1}^n (v_{1i} - \bar{v}_1)^2} \cdot \sqrt{\sum_{i=1}^n (v_{2i} - \bar{v}_2)^2}}$$


• r = valores entre -1 e +1

• $|r| > 0.70$

• 20 melhores combinações

Atributo 1	Atributo 2	Coefficiente
duration_min	duration	1.000000
distance	distance_km	1.000000
average_speed_ms	average_speed_kh	1.000000
line_category	line_color	0.952449
distance	duration	0.861906
distance	duration_min	0.861906
distance_km	duration	0.861906
distance_km	duration_min	0.861906
distance	average_speed_kh	0.754364
distance_km	average_speed_ms	0.754364
distance	average_speed_ms	0.754364
distance_km	average_speed_kh	0.754364
line_category	accessibility_info_eletric_ramp	0.538726
line_color	accessibility_info_eletric_ramp	0.529036
average_speed_ms	duration_min	0.373648
average_speed_ms	duration	0.373648
average_speed_kh	duration	0.373648
average_speed_kh	duration_min	0.373648
vehicle_time	accessibility_info_time	0.209952
station_initial_latitude	station_initial_longitude	0.204075

• Matriz de Correlação



• Atributos com boas correlações

- “line_category”, “line_color”;
- “distance”, “duration”;
- “distance”, “average_speed_kh”.

Análise dos Experimentos


- Base de dados: 12.372 registros;
- Divisão dos dados: 80% treino e 20% teste;
- Garantia de reprodutibilidade: `random_state = 0`;
- Tipo de aprendizado: Supervisionado;
- Tarefa: Regressão;
- Atributo alvo (target): “duration”;
- Métricas de avaliação:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$


- Regressão Linear Simples $\hat{y} = b_0 + b_1 \cdot x$

$b_0=499,2454$; $b_1=0,0631$

Regressão Linear - Dados de Treinamento



Regressão Linear - Dados de Teste




Métricas Diagnósticas - Regressão Linear Simples

Valores

Métricas	Treino	Teste
MAE	225,0928	221,8199
MSE	76540,3458	73952,1349
RMSE	276,6593	271,9414
R ²	0,7425	0,7445

- Regressão Linear Múltipla $y = b_0 + b_1 \cdot x_1 + b_2 \cdot x_2 + \dots + b_n \cdot x_n$



Variáveis	Coefficientes
Intercepto	-3838,7407
x1	-6,3011
x2	5,1289
x3	-169,0082
x4	23,2613
x5	-57,8439
x6	-0,9638
x7	0,0990
x8	-36,7404




Métricas Diagnósticas - Regressão Linear Múltipla

Valores

Métricas	Treino	Teste
MAE	111,9548	112,7249
MSE	23485,3171	23224,2545
RMSE	153,2492	152,3951
R ²	0,9210	0,9198

- Regressão Linear Polinomial

$$y = b_0 + b_1 \cdot x_1 + b_2 \cdot x_1^2 + \dots + b_n \cdot x_1^n$$




Grau	Dataset	MAE	MSE	RMSE	R ²
2	Treino	29,9310	1983,2615	44,5338	0,9933
	Teste	29,7637	1971,5022	44,4016	0,9932
3	Treino	14,9977	630,8934	25,1176	0,9979
	Teste	14,9525	693,5914	26,3361	0,9976
4	Treino	4,9307	51,9659	7,2087	0,9998
	Teste	4,9833	57,7164	7,5971	0,9998

- Regressão de Vetores de Suporte (SVR) - Kernel RBF

- Normalização

$$K(x, y) = \exp(-\gamma \|x - y\|^2)$$

$$X_{\text{scaled}} = \frac{X - \mu_X}{\sigma_X}$$






Métricas Diagnósticas - SVR - Kernel RBF

Valores

Métricas	Treino	Teste
MAE	24,7982	25,8052
MSE	946,1328	1194,6055
RMSE	30,7593	34,5631
R ²	0,9968	0,9959

Análises dos Experimentos

• Multilayer Perceptron (MLP)








Métricas Diagnósticas - RNA - Multilayer Perceptron

Valores

Métricas	Treino	Teste
MAE	28,0273	27,7514
MSE	1605,4831	1474,5874
RMSE	40,0685	38,4004
R²	0,9946	0,9949

• Regressão com Redes Neurais Artificiais (PyTorch)

$$f(x) = \begin{cases} x, & \text{se } x > 0 \\ 0, & \text{se } x \leq 0 \end{cases}$$




Métricas Diagnósticas - RNA - Pytorch

Valores

Métricas	Treino	Teste
MAE	113,5379	112,6421
MSE	33355,3438	31332,3613
RMSE	182,6345	177,0095
R²	0,8878	0,8918

• Regressão com Redes Neurais Artificiais (PyTorch e Cross-Validation)






Métricas Diagnósticas - RNA - Pytorch e Cross-Validation

Valores

Métricas	Treino	Teste
MAE	24,8262	24,4955
MSE	1180,5508	1142,5594
RMSE	34,3591	33,8018
R²	0,9960	0,9961

• Regressão com Redes Neurais Artificiais (PyTorch, Cross-Validation e Tuning de Hiperparâmetros)

- Hiperparâmetros otimizados:
- Batch size: 64;
- Criterion: SmoothL1Loss;
- Épocas: 100;
- Learning rate: 0.01.



Métricas Diagnósticas - RNA - Cross-Validation e Tuning

Valores

Métricas	Treino	Teste
MAE	45,8815	45,5815
MSE	4564,7407	4541,7295
RMSE	67,5629	67,3924
R²	0,9846	0,9843

Análises dos Experimentos

- Análises estatísticas dos experimentos

- MAE como métrica principal de avaliação;
- Identificar qual modelo melhor generaliza;

Método	Conjunto	MAE	MSE	RMSE	R ²
RL. Simples	Treino	225,0928	76540,3458	276,6593	0,7425
RL. Simples	Teste	221,8199	73952,1349	271,9414	0,7445
RL. Múltipla	Treino	111,9548	23485,3171	153,2492	0,9210
RL. Múltipla	Teste	112,7249	23224,2545	152,3951	0,9198
RL. Polinomial	Treino	29,9310	1983,2615	44,5338	0,9933
RL. Polinomial	Teste	29,7637	1971,5022	44,4016	0,9932
RL. SVR	Treino	24,7982	946,1328	30,7593	0,9968
RL. SVR	Teste	25,8052	1194,6055	34,5631	0,9959
RL. RNA - MLP	Treino	28,0273	1605,4831	40,0685	0,9946
RL. RNA - MLP	Teste	27,7514	1474,5874	38,4004	0,9949
RL. RNA	Treino	113,5379	33355,3438	182,6345	0,8878
RL. RNA	Teste	112,6421	31332,3613	177,0095	0,8918
RL. RNA - CV.	Treino	24,8262	1180,5508	34,3591	0,9960
RL. RNA - CV.	Teste	24,4955	1142,5594	33,8018	0,9961
RL. RNA - CV. - Tuning	Treino	45,8815	4564,7407	67,5629	0,9846
RL. RNA - CV. - Tuning	Teste	45,5815	4541,7295	67,3924	0,9843

- Teste t Pareado

- Comparar as médias MAE entre treino e teste;
- Verificar se as diferenças entre treino e teste são estatisticamente significativas;

Método	MAE Treino	MAE Teste
RL RNA - CV	24,8262	24,4955
RL SVR	24,7982	25,8052
RL RNA - CV - Tuning	45,8815	45,5815
RL Polinomial	29,9310	29,7637
RL RNA - MLP	28,0273	27,7514
RL Múltipla	111,9548	112,7249
RL RNA	113,5379	112,6421
RL Simples	225,0928	221,8199

Métrica	MAE Treino	MAE Teste
Média	75,5062	75,0730
Variância	5071,3989	4930,1672
Observações	8	8
Correlação de Pearson	0,9999	
Hipótese de diferença de média	0	
gl	7	
Stat t	0,9388	
P(T<=t) uni-caudal	0,1895	
t crítico uni-caudal	1,8946	
P(T<=t) bi-caudal	0,3791	
t crítico bi-caudal	2,3646	

- Resultados do Teste t Pareado

- Médias e variâncias semelhantes;
- Correlação próxima de 1;
- Hipótese zero, não há diferença significativa entre treino e teste;
- Stat t inferior aos valores críticos;
- P(T<=t) uni-caudal 18,95%: Probabilidade de um t mas extremo caso hipótese nula seja verdadeira;
- P(T<=t) bi-caudal 37,91%: Indica que a diferença observada não é estatisticamente significativa;

Análise Comparativa dos Experimentos

- Melhores resultados do presente trabalho

Modelo	MAE Teste
Regressão Linear com Redes Neurais Artificiais e Cross-Validation	24,4955
Regressão Linear com Vetores de Suporte (SVR)	25,8052

- Modelo escolhido:

- Regressão Linear com Redes Neurais Artificiais e Cross-Validation;
- MAE: 24,4955 segundos no conjunto de teste;
- Melhor equilíbrio entre desempenho e generalização;
- Validação cruzada garantindo maior robustez do modelo.

- Comparativo com Trabalhos anteriores

Trabalhos	Presente Trabalho - Viagens Urbanas Inteligentes: Predição de tempo de viagens urbanas utilizando modelos de Machine Learning e Redes Neurais Artificiais	(Larsen, 2020) - Predição de tempos de viagem em linhas de ônibus baseado em dados de Tráfego e Redes Neurais Artificiais
Modelos	Regressão Linear com Redes Neurais Artificiais e Cross-Validation	Redes Neurais Artificiais
Neurônios de Entrada	8	10
Camadas Ocultas	2	1
Função de Ativação	ReLu	Sigmoid
Otimizador	Adam	Nadam
RMSE	33,8018	297
Normalização	Não	Sim

Conclusão

- **Contribuições e impactos**

- Metodologia eficaz para previsão de tempos de viagem de ônibus urbano em Curitiba;
- Aprimoramento das previsões, maior precisão e menor margem de erro nas previsões;
- Viabilidade comprovada na coleta e uso de dados reais;
- Disponibilização de dados precisos para órgãos públicos;
- Melhoria no planejamento e eficiência do transporte público;
- Impacto positivo na mobilidade e qualidade de vida urbana.
- Incentivo ao uso do transporte público;
- Diminuição da emissão de poluentes e impacto ambiental positivo;
- Promoção da saúde pública por meio do incentivo a deslocamento a pé;
- Potencial aumento da produtividade ao reduzir tempos de deslocamento.

- **Resultados obtidos**

- MAE: 24,4955 segundos;
- RMSE: 33,8018;
- A métrica RMSE do presente trabalho teve uma redução de aproximadamente 88,62% em relação ao resultado do trabalho de (Larsen, 2020);
- Modelo RL RNA - CV apresentou desempenho superior na previsão de tempos de viagem.

- **Trabalhos futuros**

- Incorporar dados climáticos para refinar previsões;
- Desenvolvimento de API e camada Front-end Mobile para que diversas pessoas possam consumir estas informações;
- Mensurar impacto na qualidade do transporte público;
- Analisar possíveis reduções no tempo de espera dos passageiros.

Referências

- 1 GRUS, J. **Data Science do Zero**: Primeiras regras com o python. Rua Viúva Cláudio, 291 - Bairro Industrial do Jacaré, CEP: 20.970-031, Rio de Janeiro (RJ): Alta Books Editora, 2016.
- 2 LARSEN, G. H. Predição de tempos de viagem em linhas de Ônibus baseado em dados de tráfego e redes neurais artificiais. **POLI-USP**, Escola Politécnica da Universidade de São Paulo, 2020. Disponível em: <https://www.teses.usp.br/teses/disponiveis/3/3142/1de-20012021-163526/publico/GustavoHenriqueLarsenCorr20.pdf>. Acesso em: 27 jul. 2020.
- 3 SILVA SARAJANE MARQUES PERES, C. B. Leandro Augusto da. **Introdução à Mineração de Dados**: Com aplicações em r. Rua Sete de Setembro, 111 – 16o andar 20050-006 – Centro – Rio de Janeiro (RJ) - Brasil: Elsevier Editora Ltda., 2016.
- 4 GÉRON, A. **Mãos à Obra: Aprendizado de Máquina com Scikit-Learn TensorFlow**: Conceitos, ferramentas e técnicas para a construção de sistemas inteligentes. Rio de Janeiro (RJ): Alta Books, 2019.
- 5 LUÍS, M. O. B. L. Desenvolvimento de sistema de inteligência artificial (ia) baseado em reconhecimento de padrões para análise de rotas veiculares. **Journal Iberamia**, Universidade Regional do Noroeste do Estado do Rio Grande do Sul, 2020. Disponível em: <https://journal.iberamia.org/index.php/intartif/article/view/339/108>. Acesso em: 2020.
- 6 FAYYAD PIATETSKY SHAPIRO, G. S. P. . U. R. U. M. **Advances in Knowledge Discovery and Data Mining**. United States (CA): AAAI Press, 1996. The Mit Press.
- 7 CIVALI, V. de O. Sistema algorítmico de rede neural artificial para previsão da localização de ônibus de linha em quedas de sinal. **UNICAMP**, XXIX Congresso de Iniciação Científica UNICAMP, 2021. Disponível em: <https://prp.unicamp.br/inscricao-congresso/resumos/2021P17874A33759O2972.pdf>. Acesso em: 2021.
- 8 MACHADO, S. d. S. B. C. Influências da inteligência artificial (ia) na otimização do tráfego urbano: um referencial teórico. **PUC**, Editora Científica Digital, v. 2, 2022. Disponível em: <https://downloads.editoracientifica.com.br/articles/220207766.pdf>. Acesso em: 2022.
- 9 LUÍS, M. O. B. L. Desenvolvimento de sistema de inteligência artificial (ia) baseado em reconhecimento de padrões para análise de rotas veiculares. **Journal Iberamia**, IBERAMIA, v. 23, 2020. Disponível em: <https://journal.iberamia.org/index.php/intartif/article/view/339/108>. Acesso em: 2020.
- 10 PARANÁ, D. N. da S. **Física para o Ensino Médio**: Volume Único. Rua Barão de Iguape, 110 - CEP 01507-900 - São Paulo (SP): Editora Ática, 2003.
- 11 LAROSE, C. D. L. D. T. **Discovering Knowledge in Data: An Introduction to Data Mining**. [S.l.]: John Wiley Sons, 2014. Inc. All rights reserved.